【TERM 最終発表】
RDMAを用いた，遠隔ベアメタルマシン
デバッグのための論理メモリの参照

Arch B3 tatsu
親: macchanさん,soraさん

背景

- OSデバッグやメモリフォレンジックをする際,
  物理マシン・仮想マシンを解析
  - 特に，カーネルパニック時の解析にはVMを利用
  - XenやQEMU＋KVMなど
- 関連ソフトウェア: libvmi, google/rekallなど

課題

- 物理マシンに対して，カーネルパニック時におけるメモリ解析手段が存在しない
- OSが提供していた機能が使えなくなるため
  - Memory Management Unit
  - システムコール
  - カーネルシンボル

目的

- 遠隔ベアメタルマシンの物理メモリの監視アーキテクチャを確立
  - 外部電源・外部プロセッサで動作
- **カーネルパニック時に特定のプロセスの仮想アドレス空間を復元**
  - **カーネルパニック時の特定プロセスの変数を参照**

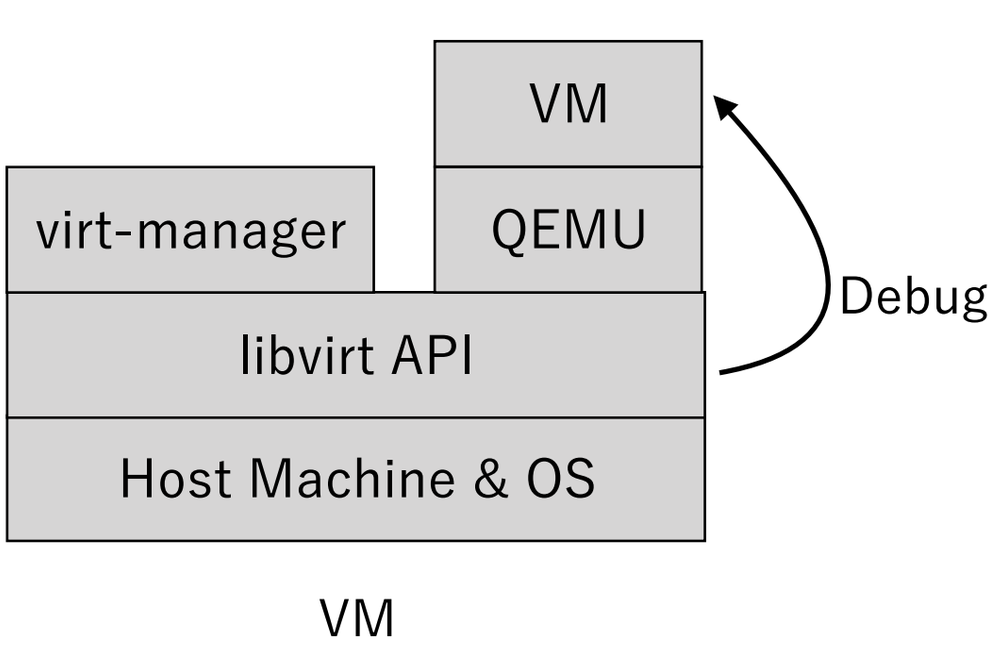

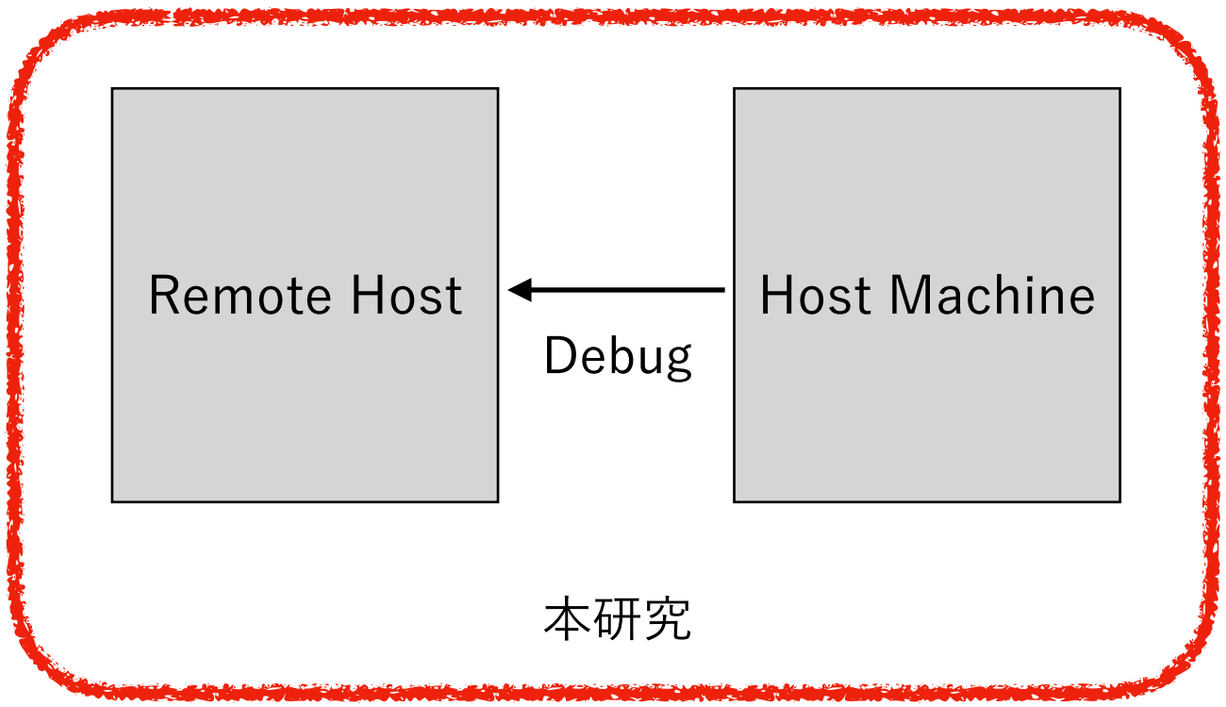

x86-64 Linuxのページウォーク

- Linuxではページング機構を通して，プロセス中で仮想アドレスを物理アドレスへ変換している．
  - 各テーブルをたどる行程をページウォークと呼ぶ

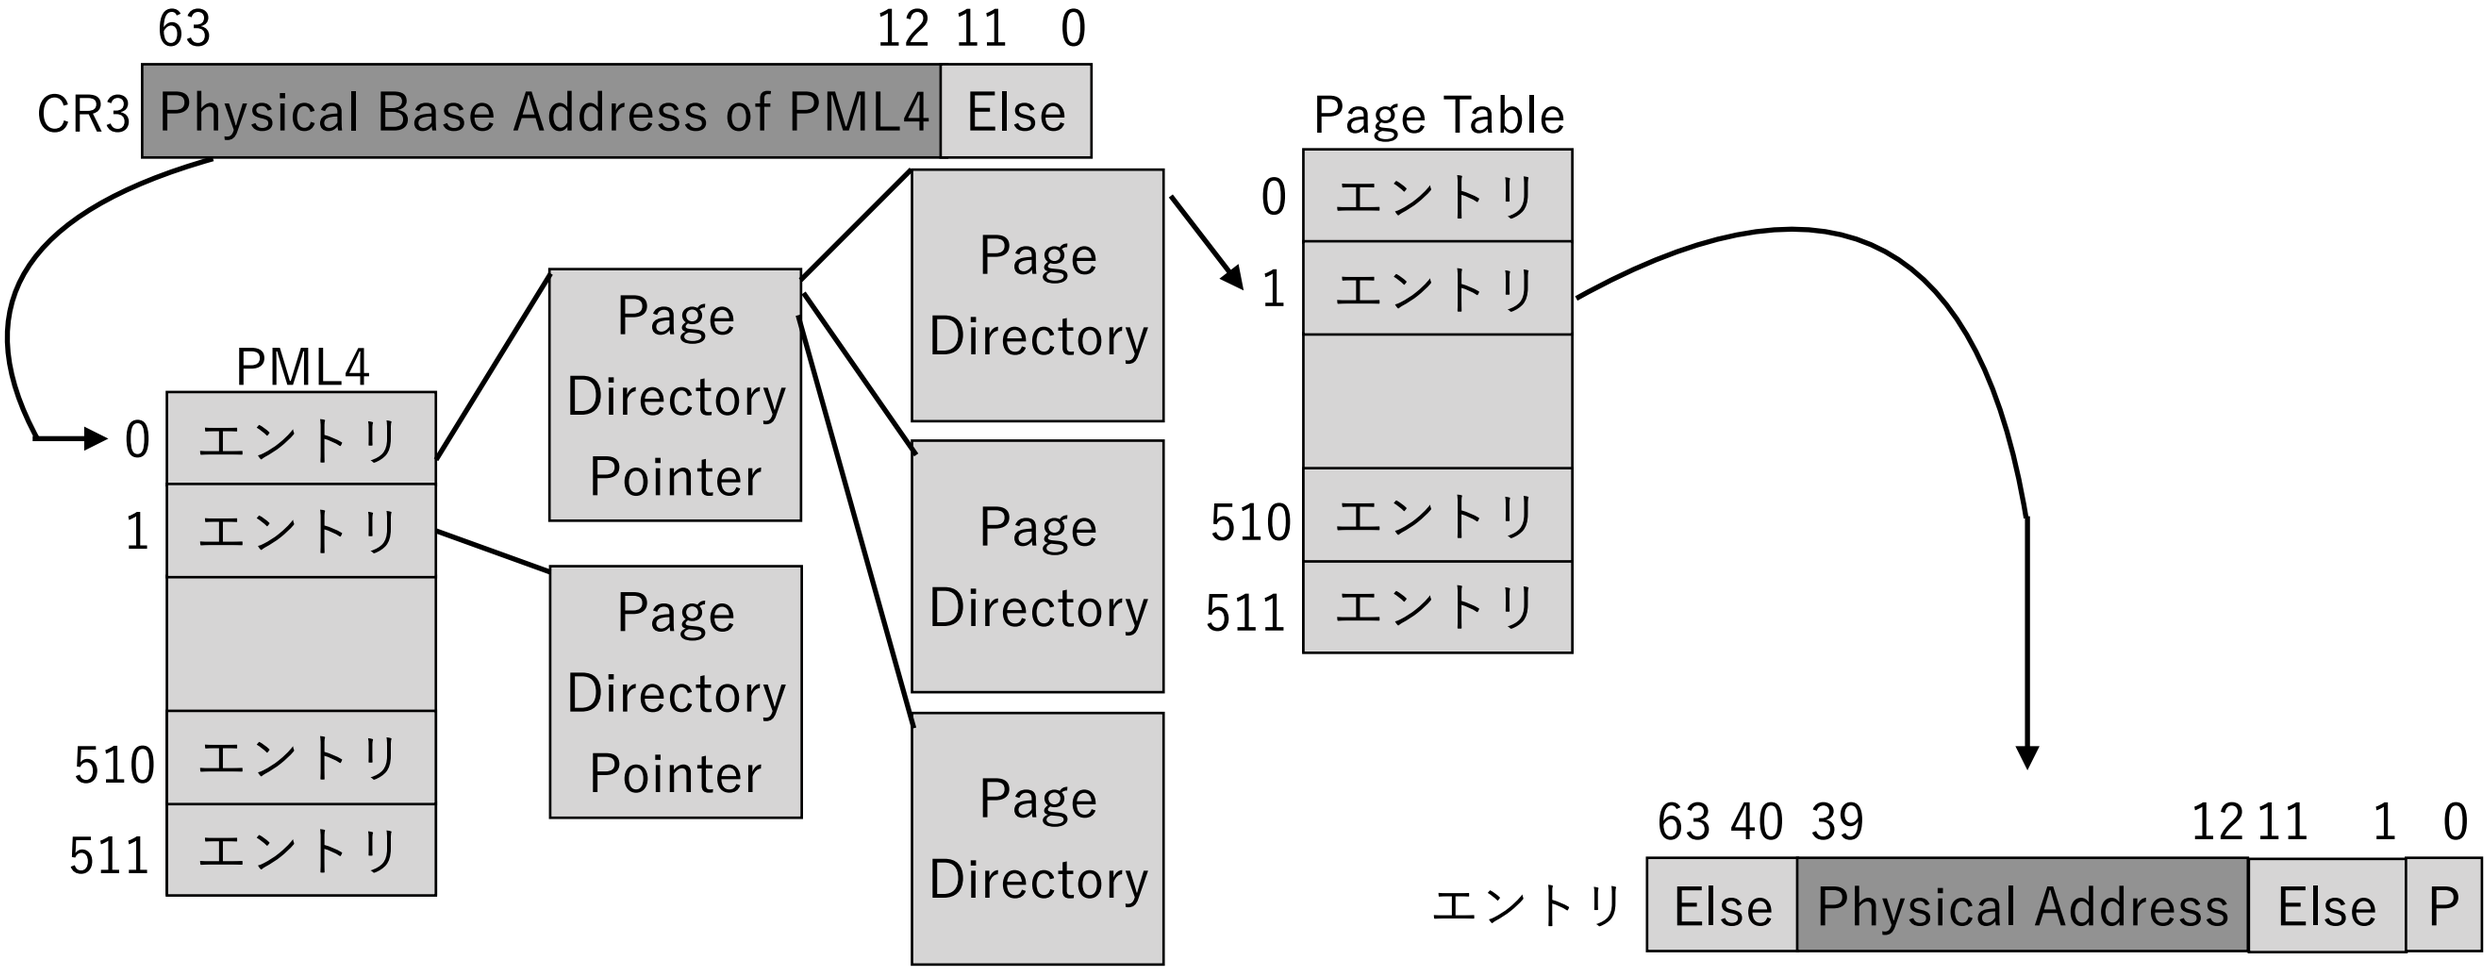

x86-64 Linuxのページウォーク

- **CR3**の値をもとに，ページウォークをし仮想アドレスを物理アドレスに変換

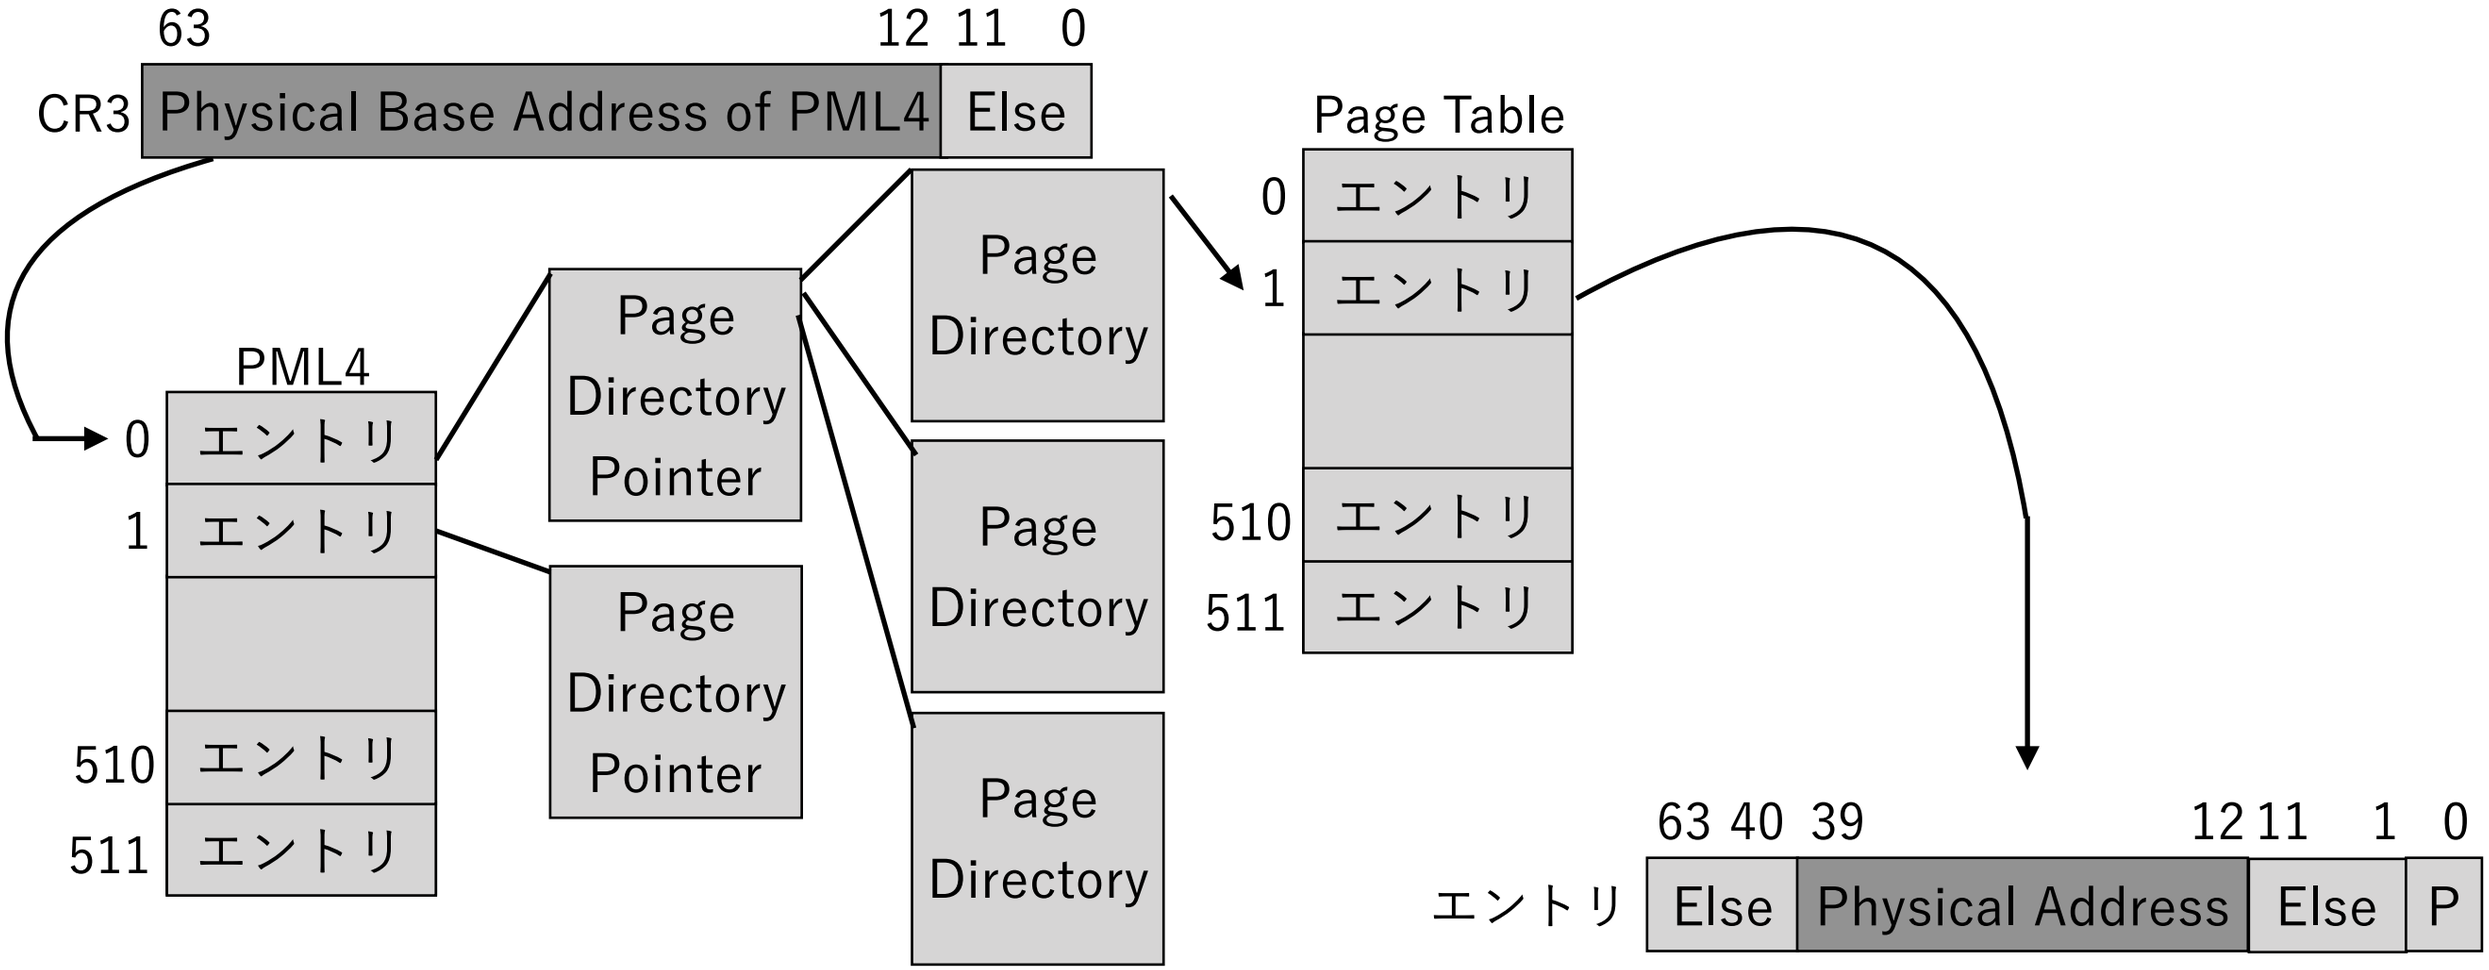

x86-64 Linuxのページウォーク

- **CR3**とは，ページウォークの起点であるPML4の物理アドレスを保持するレジスタ
  - **プロセスごとに設定**されている

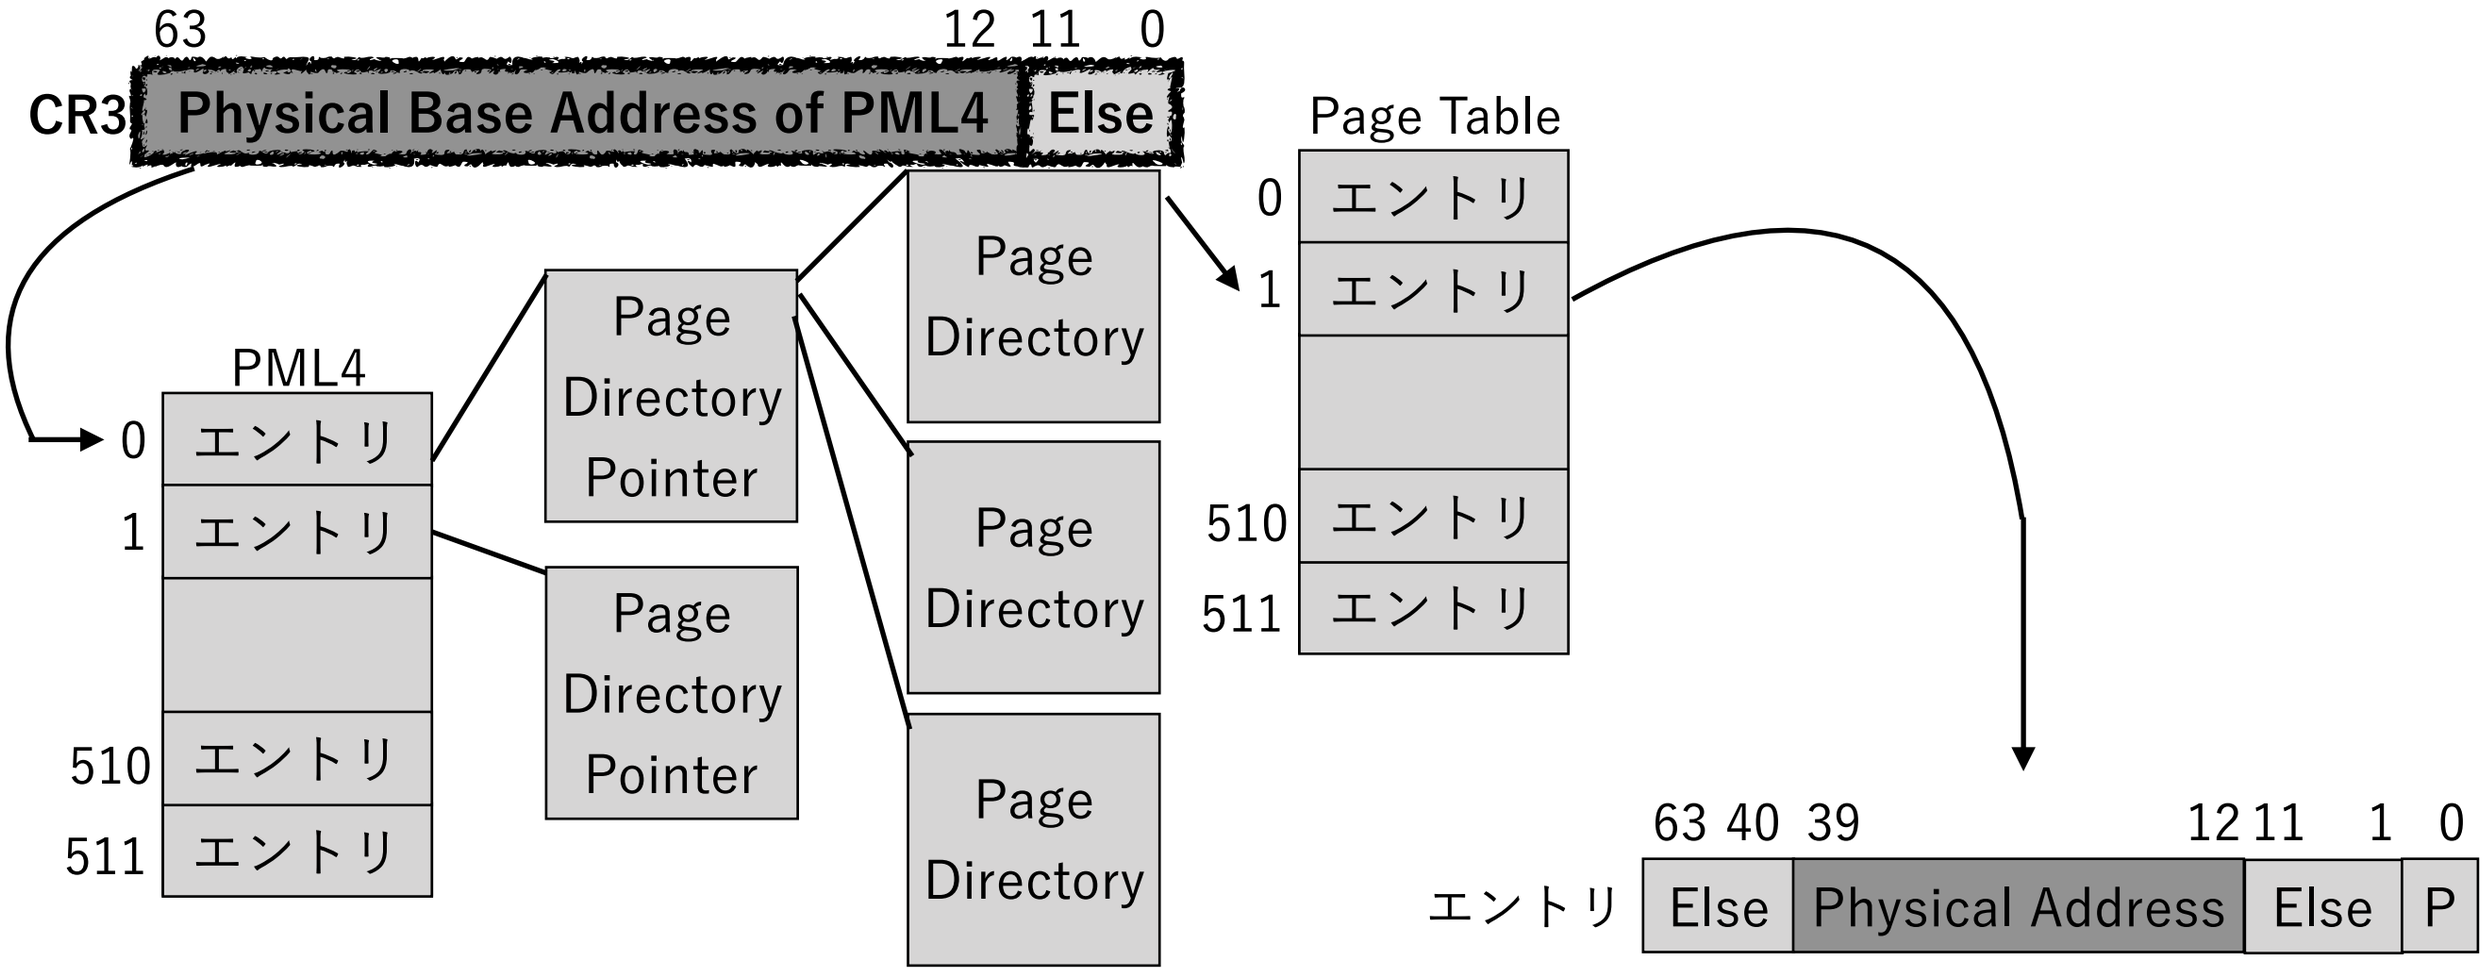

x86-64 Linuxのページウォーク

- テーブルは4段階存在(Page Map Level 4, Page Directory Pointer, Page Directory, Page Table)
- 仮想アドレスは以下のフィールドに分割
- それぞれのフィールドには各テーブルのインデックス(0~511)が格納されている

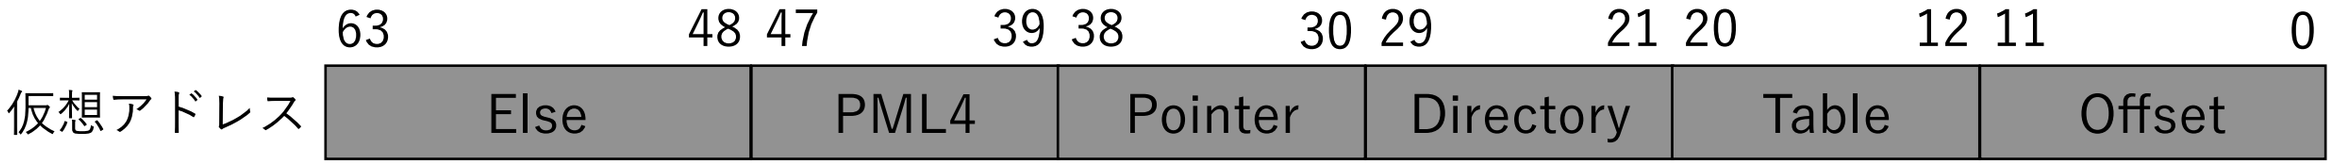

x86-64 Linuxのページウォーク

- 仮想アドレスが**0x1000**の場合
- PML4 = **0**, Page Directory Pointer = **0**, Page Directory = **0**, Page Table = **1**

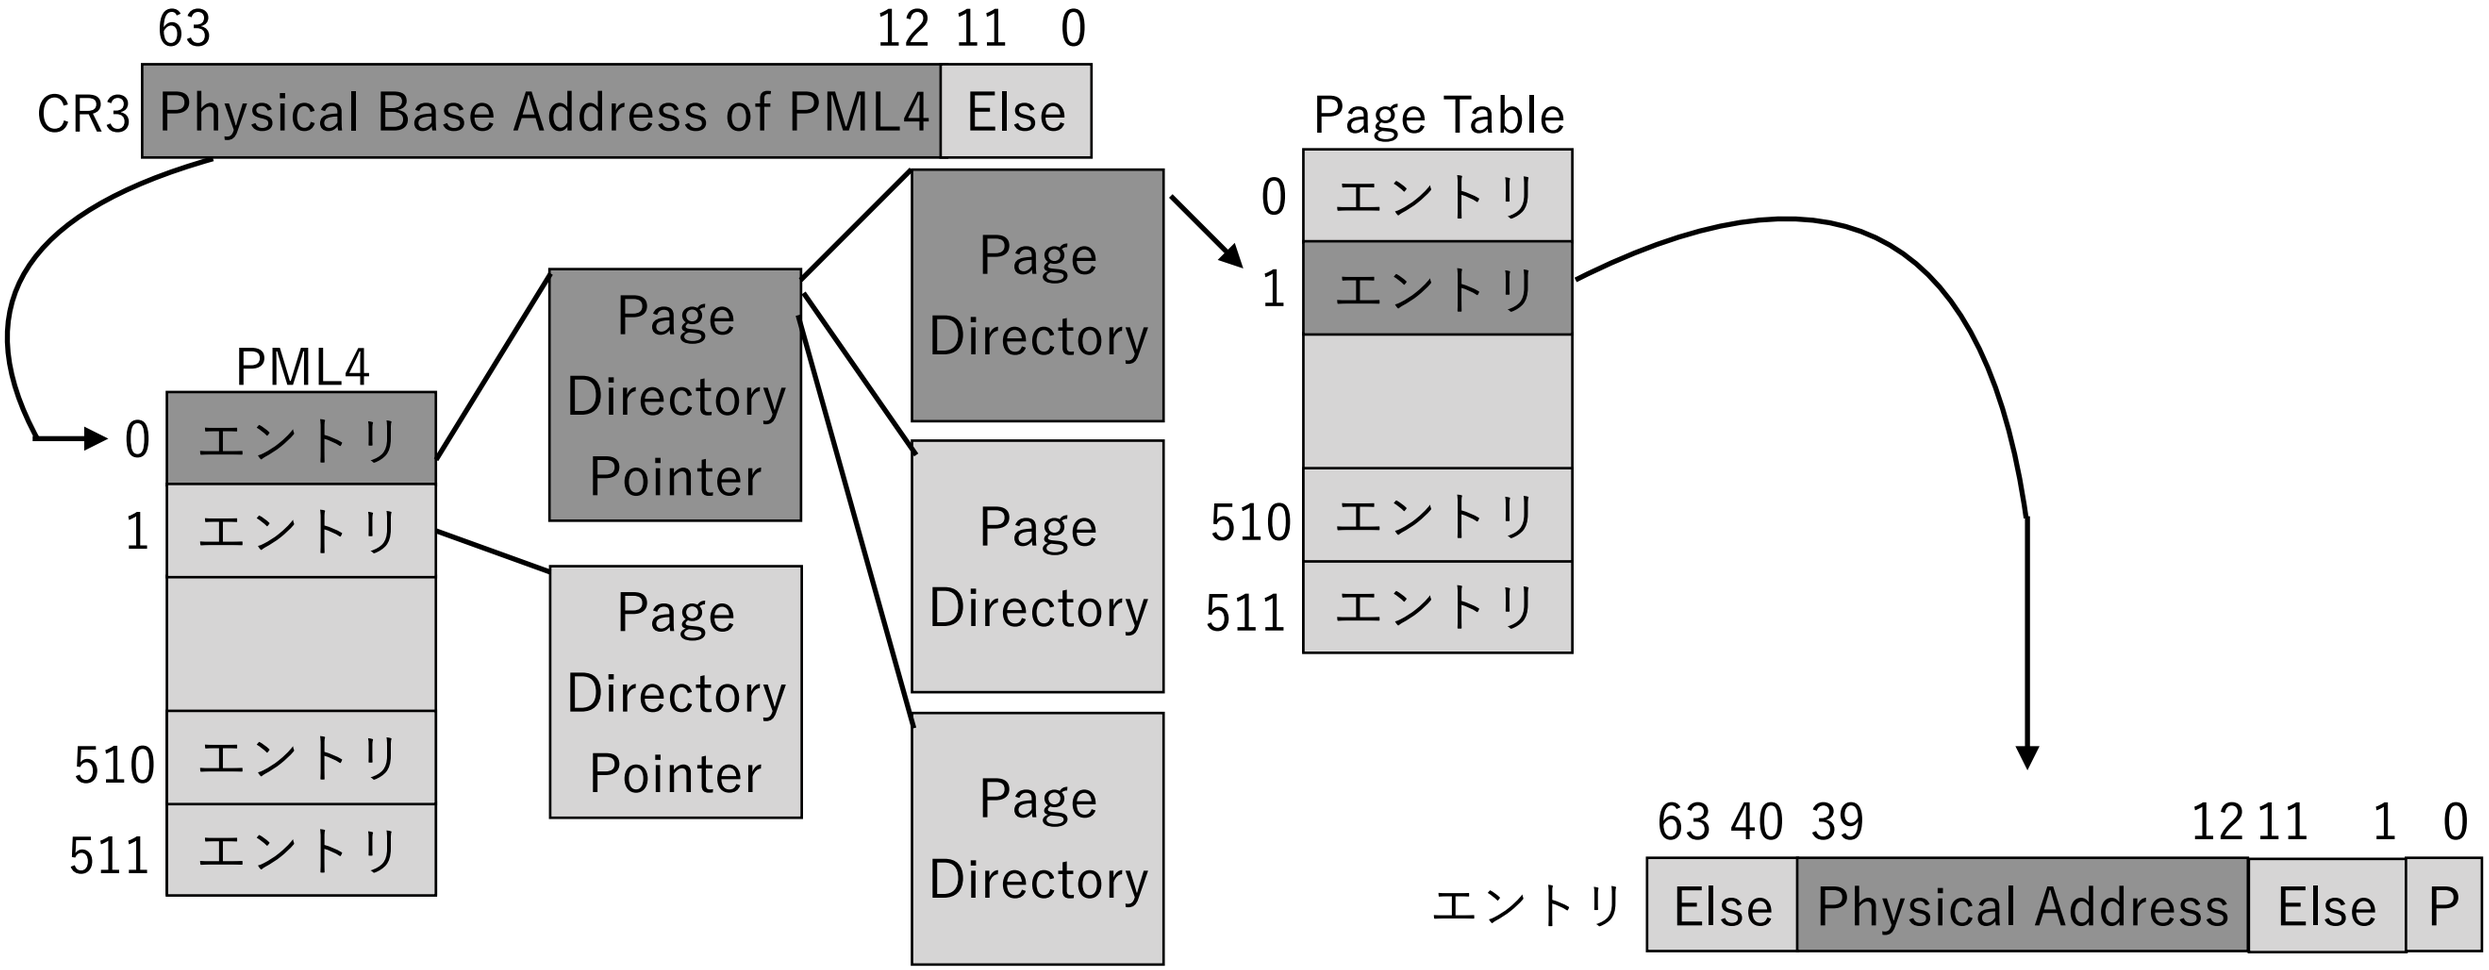

アプローチ

- ページウォークのロジックを解析

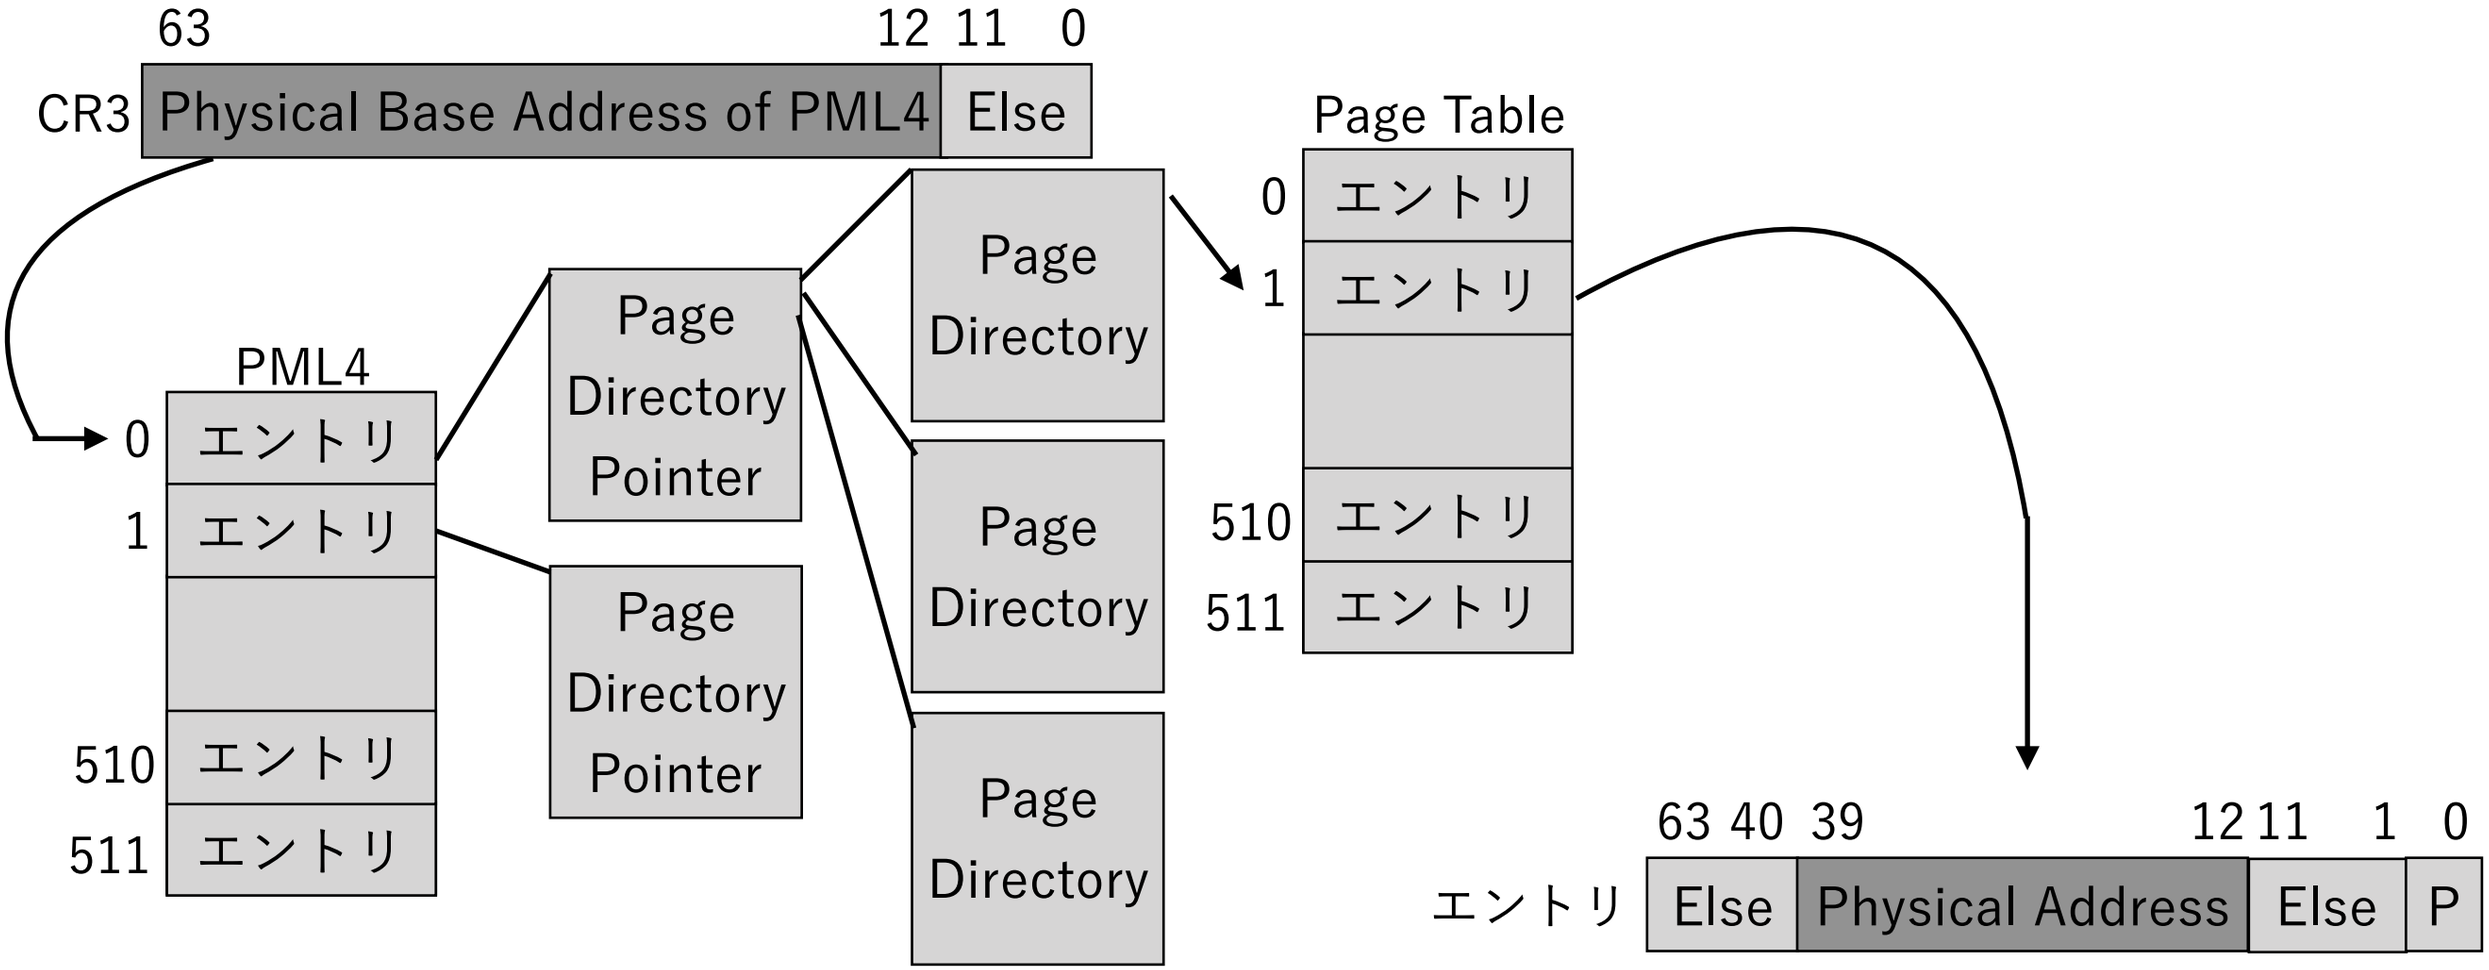

アプローチ

- テーブルの全エントリを本研究のプログラムで保持
- ロジックを逆算し仮想アドレス空間を復元し，論理メモリを参照する

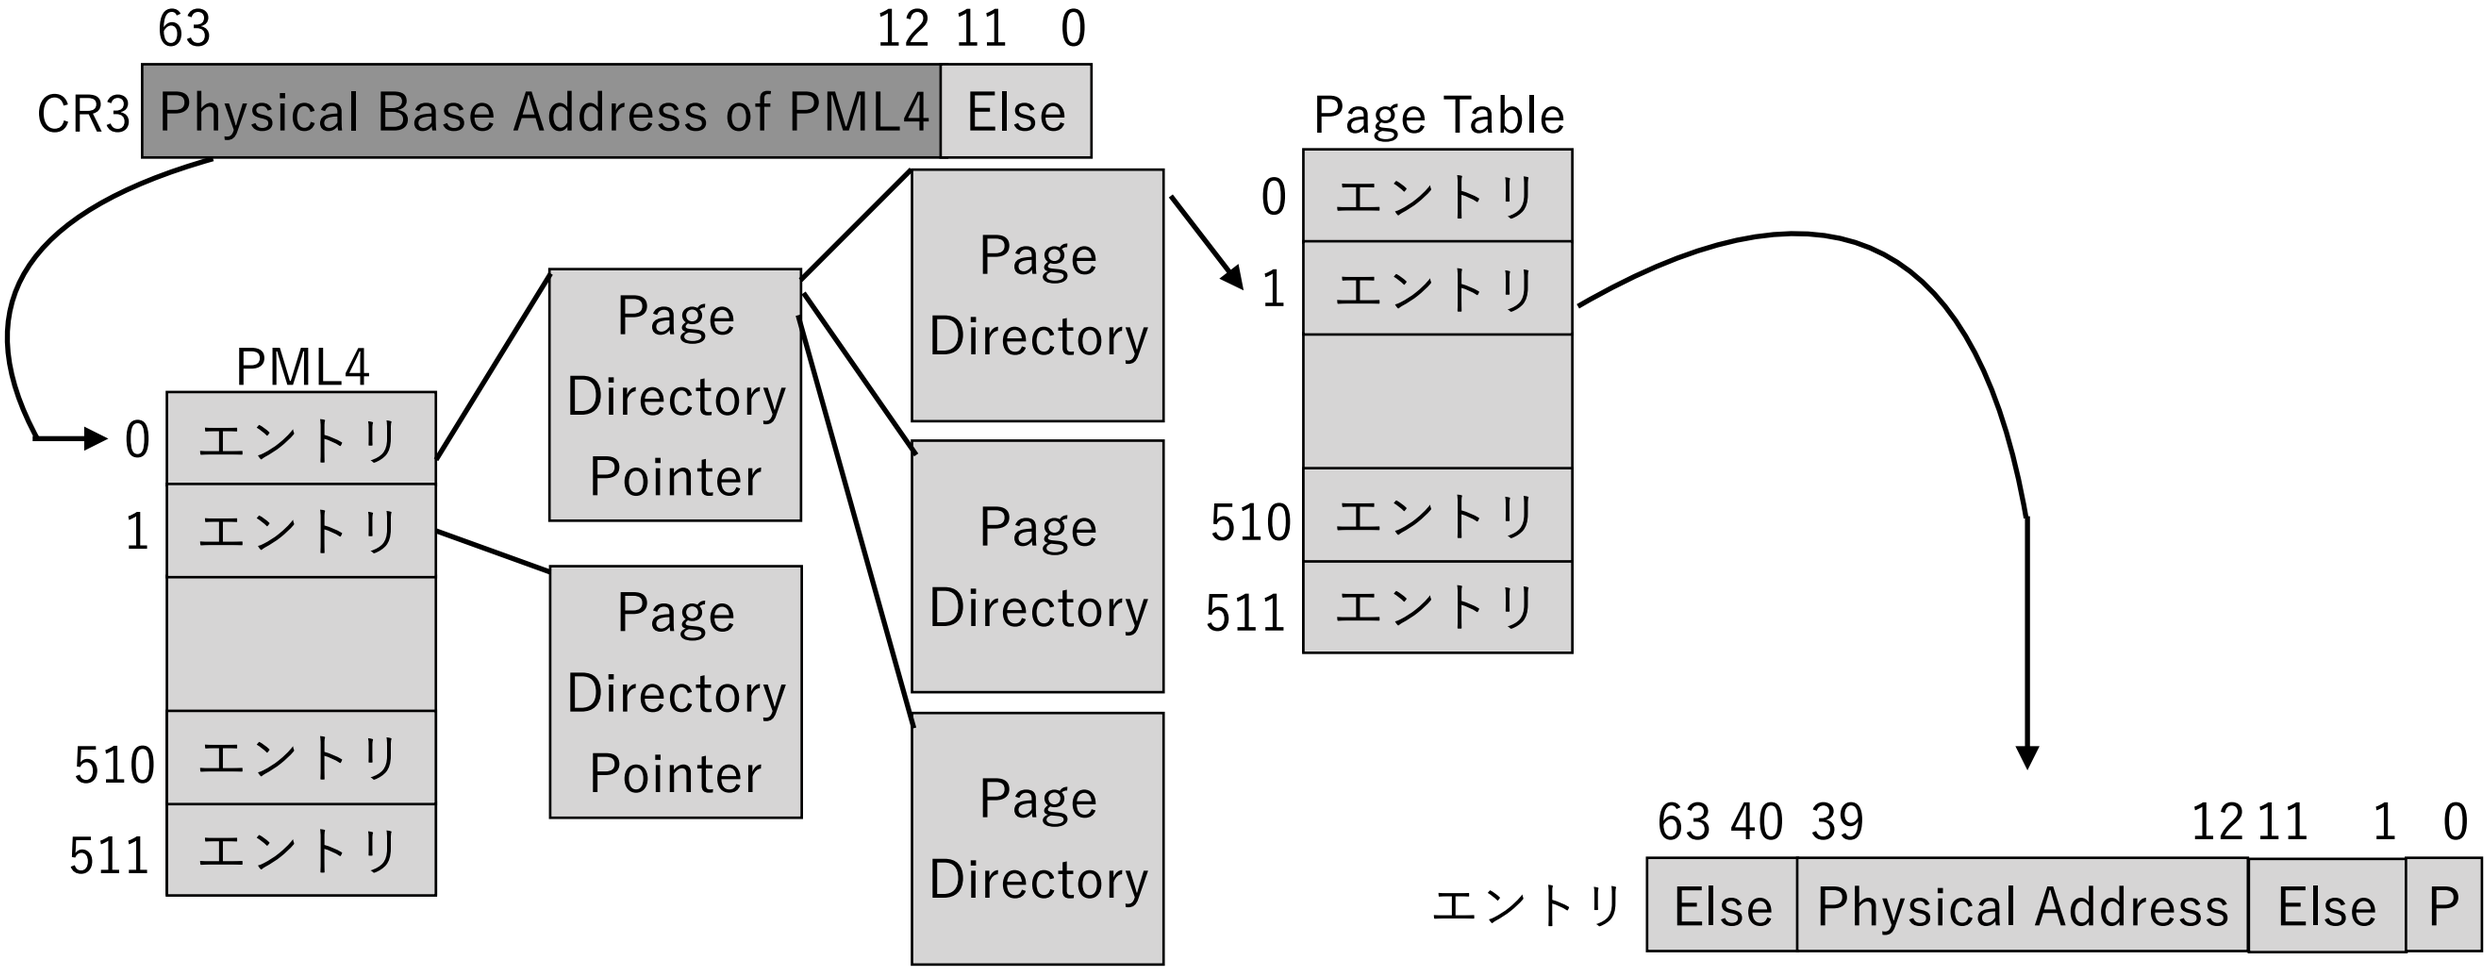

環境

- 監視プロセスが動くホスト
  - x86-64 Linux
- 監視対象ホスト
  - x86-64 Linux

システム概要

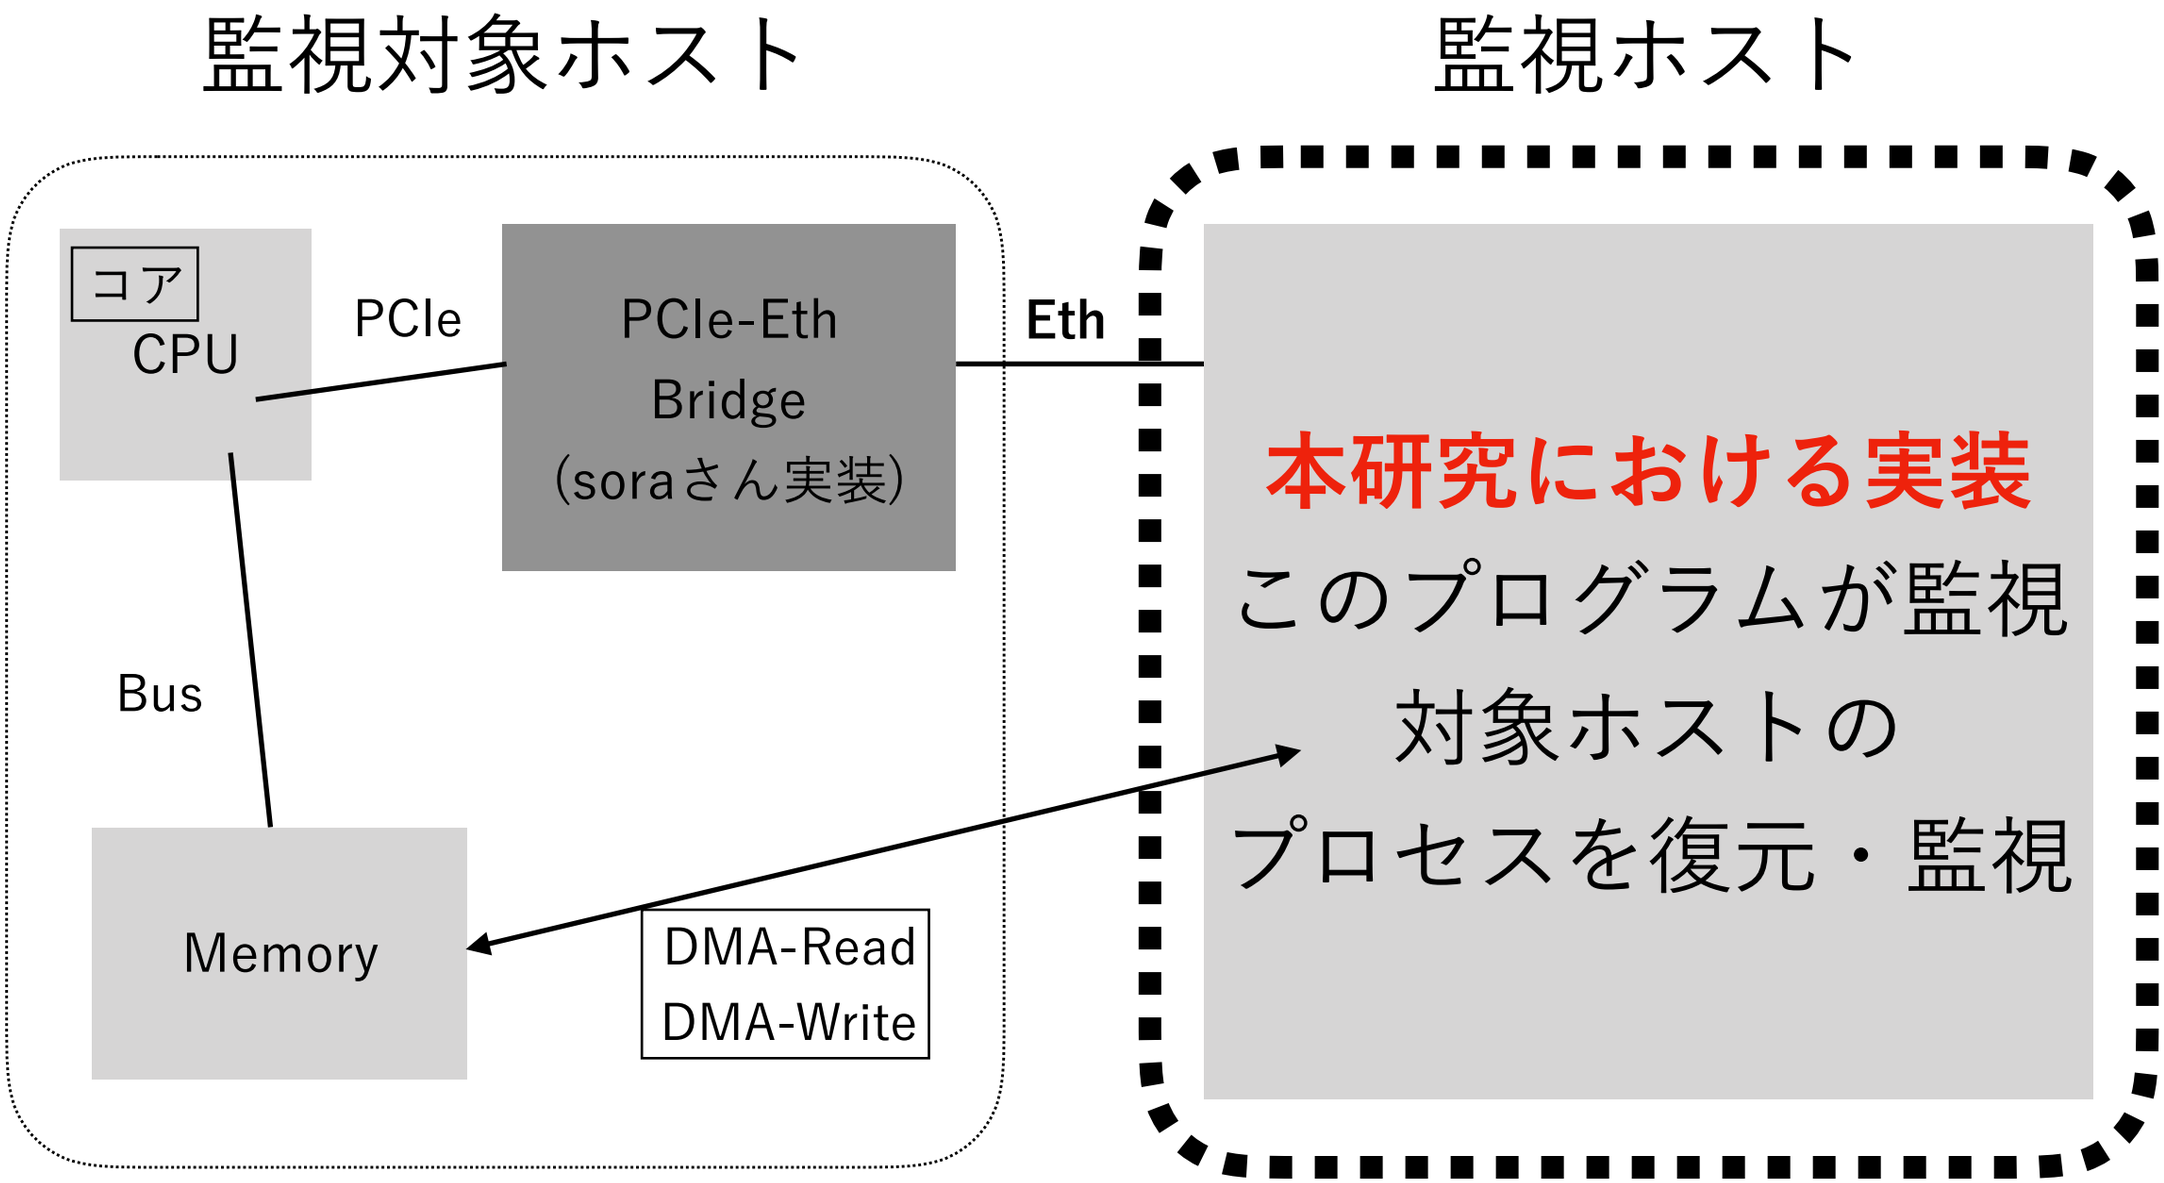

PCIe-Eth Bridgeのデータ構造

システム概要

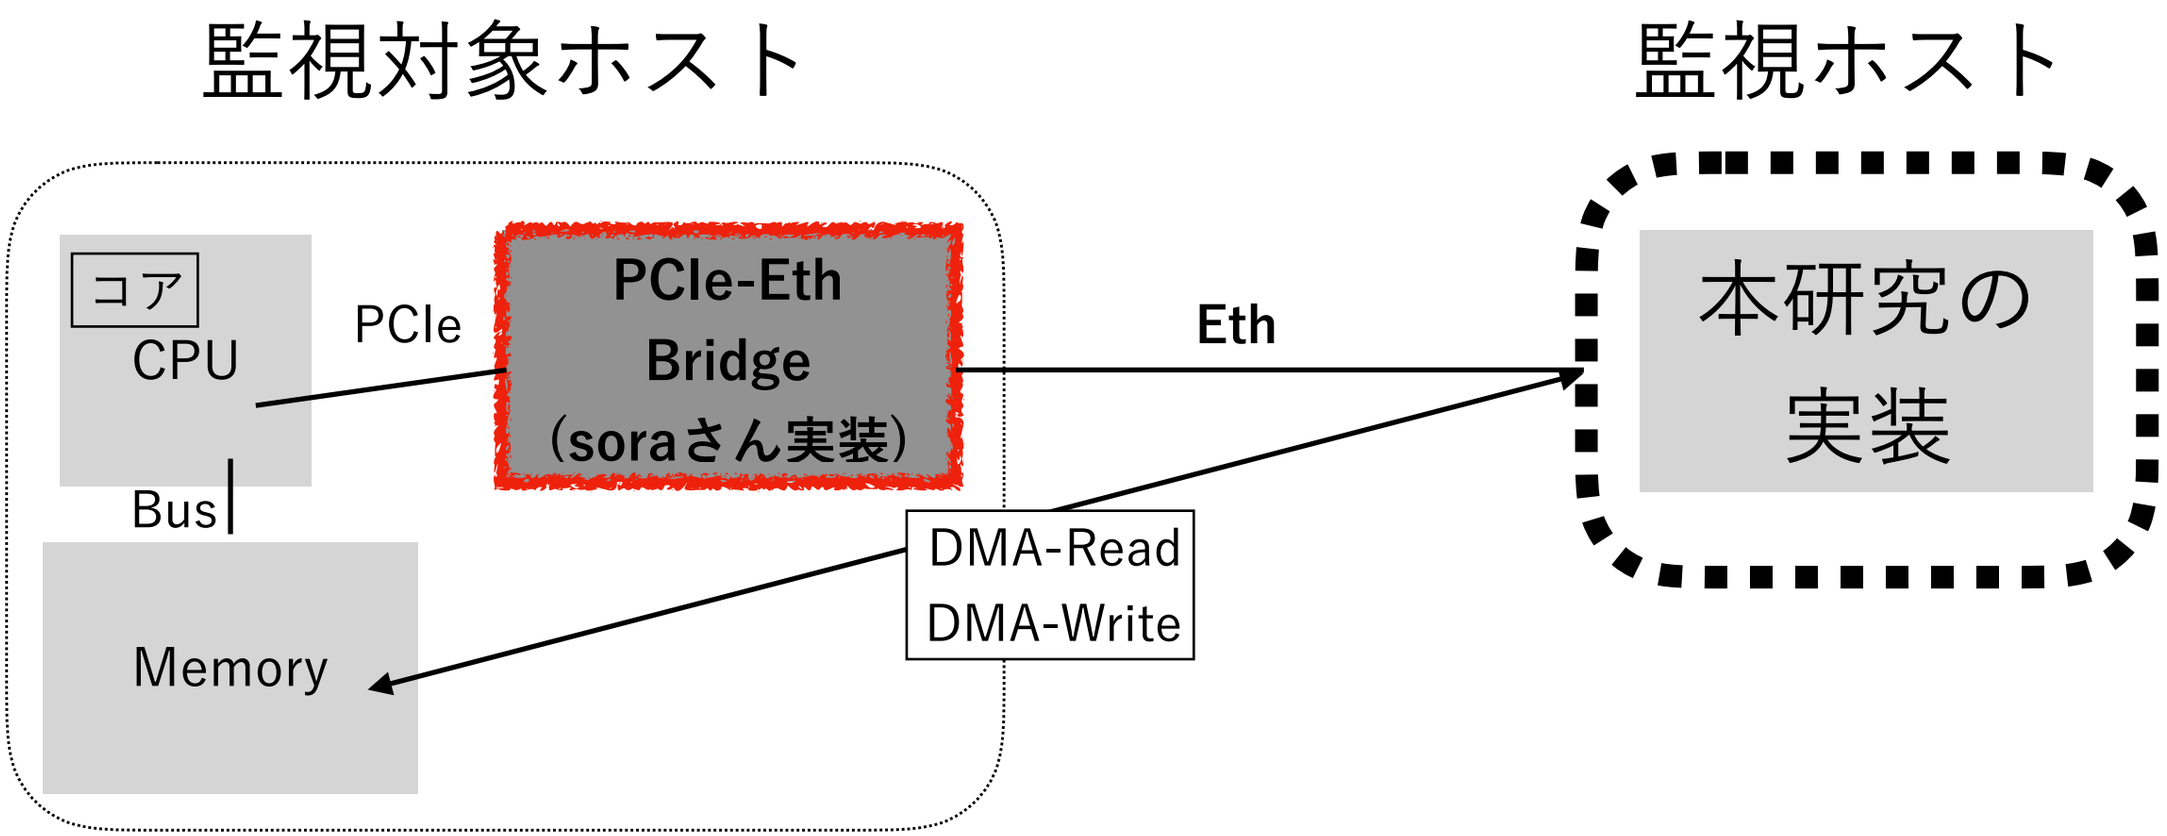

- PCI MessageとEthernetフレームを変換するFPGAデバイス
  - 物理的に設置する

システム概要

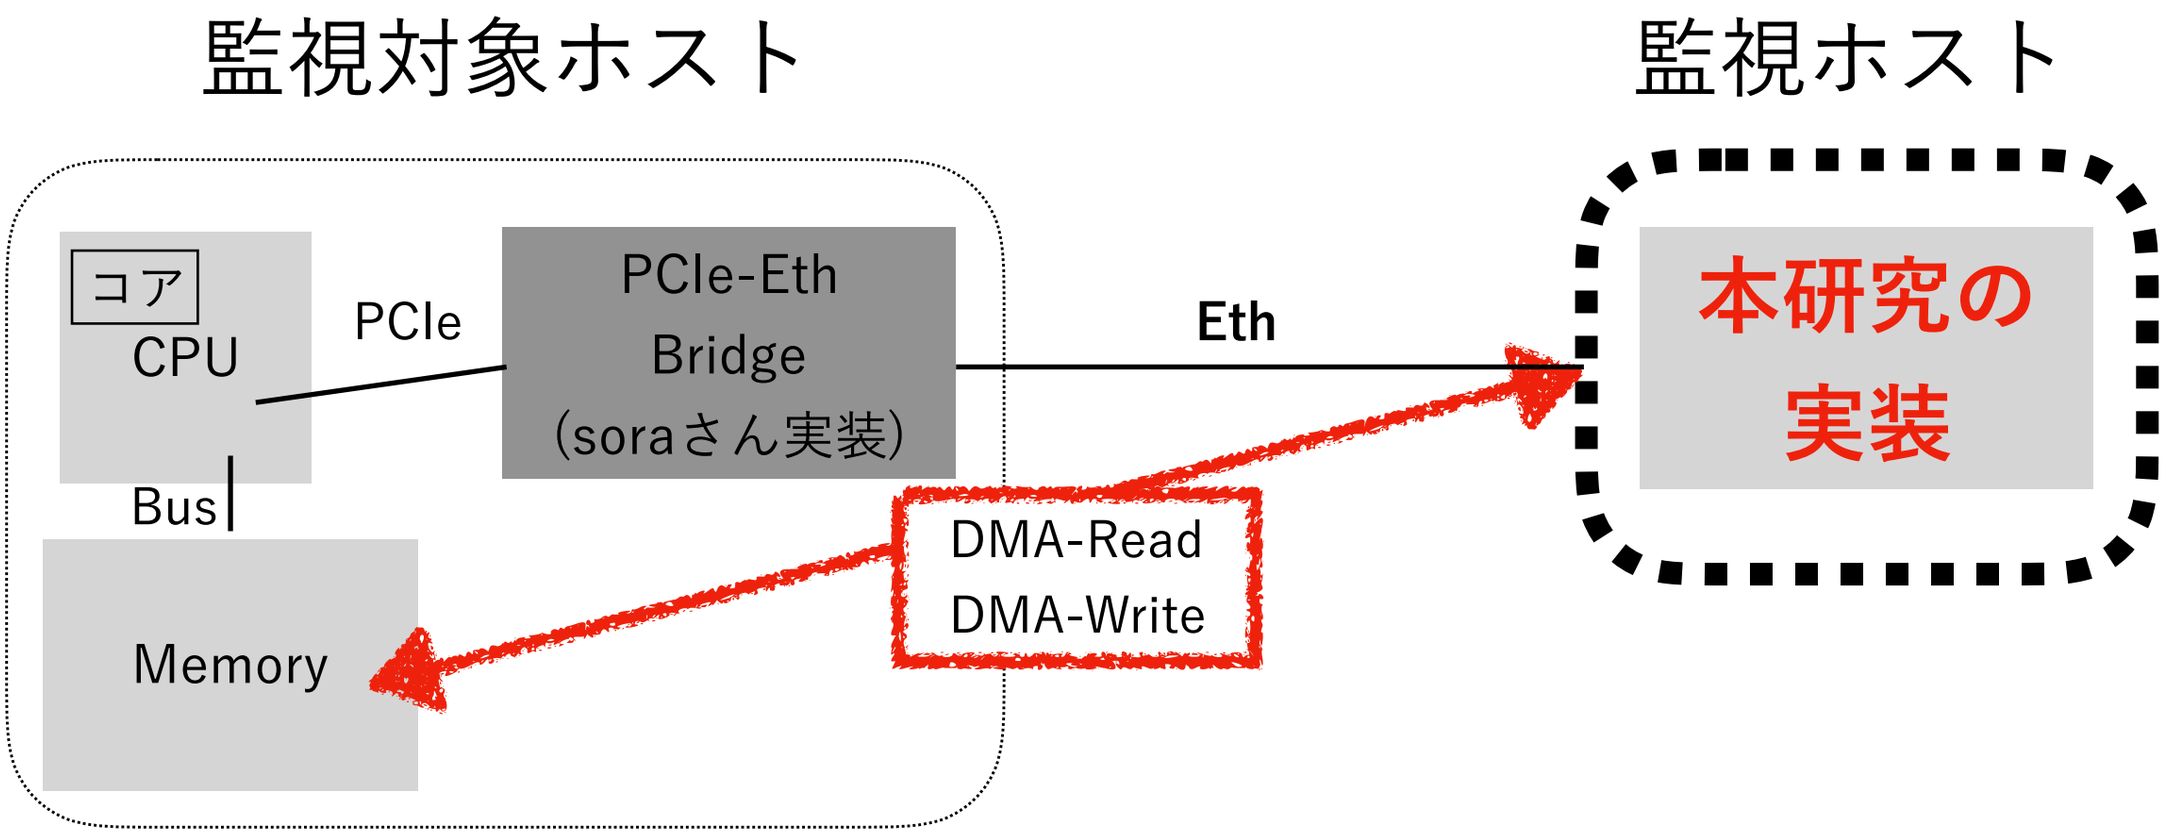

- PCIe Eth Bridgeの手続き(read/write)を連続で呼び出す(4 Bytesごと)
  - 連続した領域の値を取得

実装

- CR3の値を**監視対象ホストから通知**
  - CR3はレジスタであるため現在の値をメモリから参照できないため
- https://github.com/dooooooooingggggg/dmaLinux/blob/master/src/dmaLinux.c

実装

- 通知されたCR3の値を受け取る(macchanさんのカーネルモジュールを拡張)
- CR3を起点に全てのエントリの値を取得し**配列に保持**
  - 値を取得する際は，PCIe-Eth-Bridgeの手続きを呼び出す

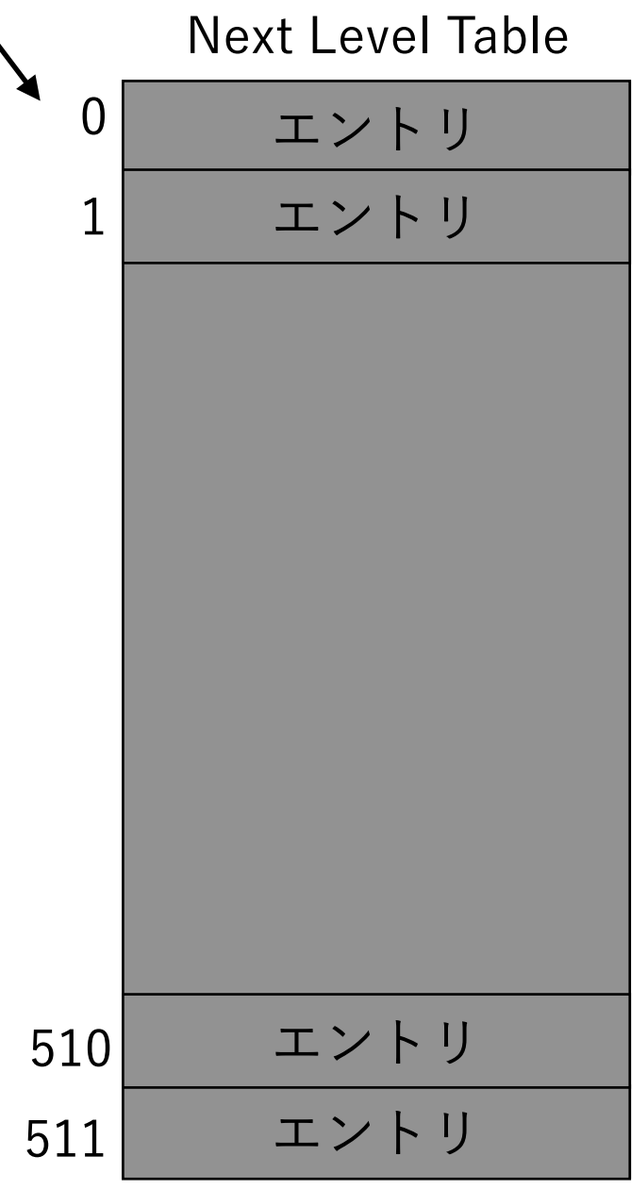

実装

- 最終的にPage Tableから物理アドレス，値を取得

- 以下の処理に通すことで仮想アドレスの復元が完了

```
(pml4Index << 39)+ (pdpIndex << 30) +
(pdIndex << 21) + (ptIndex << 12) +
offset;
```

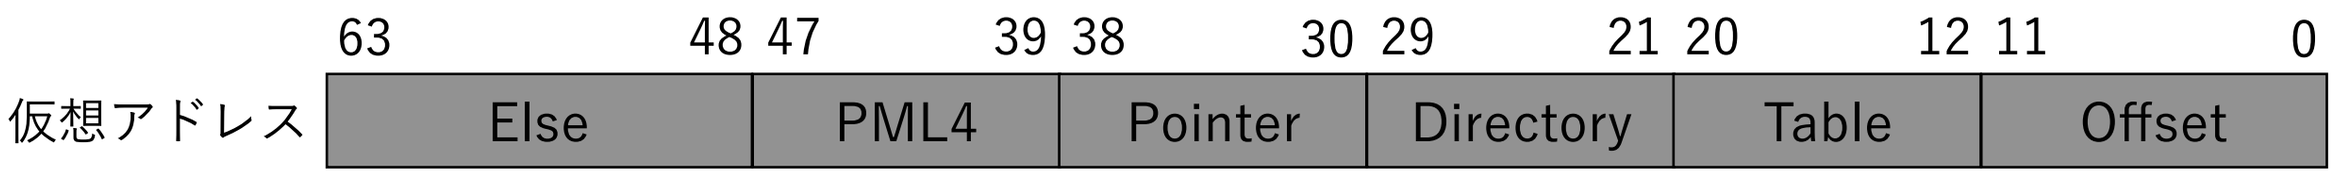

評価

- **カーネルパニック時の対象プロセスの論理メモリ参照の可否**
  - 状態を正しく取得できるか？
    - 手段として，**現在の時間を変数として保持するプロセスを監視**する
    - 手順として，監視プロセスが動いている最中に，別コンソールから，意図的にカーネルパニックを起こす

```
$ sudo su -
root$ echo c > /proc/sysrq-trigger
```

評価

- 監視するプロセスの詳細
- https://github.com/dooooooooingggggg/getcr3/blob/master/user.c
  - CR3の値をカーネルモジュール経由でprintf()
    - macchanさん実装のカーネルモジュールを拡張
  - 現在のUNIX TIMEをprintf()
  - 監視対象ホストでのプロセスの出力例

```
# a:1548316892(0x5c4970dc) at 0x7fff6509aa90
# CR3: 0x274be2000
```

評価

- 本研究における実装の出力結果(解析結果)

```
# 0x7fff65099000(phys[0x2697c9000]) : 0x0
# 0x7fff65099008(phys[0x2697c9008]) : 0x0
# 0x7fff65099010(phys[0x2697c9010]) : 0x0
# 0x7fff65099018(phys[0x2697c9018]) : 0x0
# 0x7fff65099020(phys[0x2697c9020]) : 0x0
# 0x7fff6509aa8c(phys[0x2697e5a8c]) : 0x5c4970de00000028
# 0x7fff6509aa94(phys[0x2697e5a94]) : 0x6509aa9000000000
# 0x7fff6509aa9c(phys[0x2697e5a9c]) : 0x8005003300007fff
# 0x7fff6509aaa4(phys[0x2697e5aa4]) : 0x75cf3b0000000000
# 0x7fff6509aaac(phys[0x2697e5aac]) : 0x309c3230ffff8802
# 0x7fff6509b000(phys[0x269cba000]) : 0x0
# 0x7fff6509b008(phys[0x269cba008]) : 0x0
# 0x7fff6509b010(phys[0x269cba010]) : 0x0
# 0x7fff6509b018(phys[0x269cba018]) : 0x0
# 0x7fff6509b020(phys[0x269cba020]) : 0x0
```

評価

- 本研究における実装の出力結果(解析結果)

```
# 0x7fff65099000(phys[0x2697c9000]) : 0x0
# 0x7fff65099008(phys[0x2697c9008]) : 0x0
# 0x7fff65099010(phys[0x2697c9010]) : 0x0
# 0x7fff65099018(phys[0x2697c9018]) : 0x0
# 0x7fff65099020(phys[0x2697c9020]) : 0x0
# 0x7fff6509aa8c(phys[0x2697e5a8c]) : 0x5c4970de00000028
# 0x7fff6509aa94(phys[0x2697e5a94]) : 0x0000000000000000
# 0x7fff6509aa9c(phys[0x2697e5a9c]) : 0x0000000000007fff
```

仮想アドレス　物理アドレス　変数の値

```
# a:1548316892(0x5c4970dc) at 0x7fff6509aa90
# CR3: 0x274be2000
```

```
# 0x7fff6509b008(phys[0x269cba008]) : 0x0
# 0x7fff6509b010(phys[0x269cba010]) : 0x0
# 0x7fff6509b018(phys[0x269cba018]) : 0x0
# 0x7fff6509b020(phys[0x269cba020]) : 0x0
```

- **0x7fff6509aa90**に変数の値が見える
- **5c4970de**(= **1548316894** (UNIX TIME))にカーネルパニックが発生

結論

- CR3が通知された状態において，論理メモリの参照が可能なことが実証
  - 参照したい変数の値を確認できた
- 物理メモリをみると，飛ばし飛ばしに存在しているプログラムの論理メモリを参照できた
- プロセス中では連続した領域に見える

今後の展望(卒論に向けて)

- カーネル空間にあるtask_structをメモリのみから探す
  - CR3の値はカーネルのtask_struct->mm_struct->pgdに格納
  - 値の通知なしで全プロセスのカーネルパニック時の論理メモリの参照が可能となる
- PCIe Eth Bridgeを拡張
  - 現在は局所的な範囲でのみ動作する
- 物理メモリの値のみがわかる状態で，どこまで遠隔ベアメタルマシンのコンテキストを復元できるかを模索